M M D

MAESTRÍA EN MINERÍA DE DATOS · UTN FACULTAD REGIONAL ROSARIO

Aplicaciones de Minería de Datos a Economía y Finanzas

Clase 2 — Database Marketing y Fuentes de Datos

Dr. Darío Ezequiel Díaz

drdarioezequieldiaz@gmail.com

Jueves 16 de abril de 2026 · 18:00–22:00 hs

Hoja de ruta de la clase

01 **Recapitulación de la Clase 1**
Repaso de marcos metodológicos: KDD, CRISP-DM, SEMMA, DMAIC

02 **Database Marketing en profundidad**
Concepto, evolución, ciclo operativo, CLV y segmentación analítica

03 **Modelos de propensidad**
Scoring de propensión, detección de churn, ofertas personalizadas

04 **Fuentes de datos económico-financieros**
BCRA, INDEC, Kaggle, UCI, organismos multilaterales

05 **Bases de datos aplicadas**
Tipología de variables, calidad del dato, problemas frecuentes

06 **Práctica guiada en Google Colab**
Carga y exploración de un dataset financiero real con pandas y tidyverse

¿Qué construimos la semana pasada?

KDD

La minería de datos como fase central del proceso de descubrimiento de conocimiento en bases de datos.

CRISP-DM

Metodología iterativa de 6 fases: estándar de facto en la industria para proyectos de minería de datos.

SEMMA

Marco técnico del SAS Institute (Sample, Explore, Modify, Model, Assess). Sin fase de negocio.

DMAIC

Ciclo de mejora continua de Six Sigma con énfasis en control de calidad y reducción de variabilidad.

Supervisado vs. No Supervisado · Database Marketing (introducción) · Configuración de Google Colab y repositorio

Database Marketing: Concepto y alcance

Disciplina que articula la gestión sistemática de bases de datos con las estrategias de marketing mediante la aplicación de técnicas analíticas, con el propósito de construir perfiles detallados de clientes y maximizar el Customer Lifetime Value (CLV).

Datos

Variables demográficas, transaccionales, de comportamiento digital e historial crediticio integradas desde múltiples sistemas fuente.

Analítica

Modelos predictivos, segmentación automatizada, algoritmos de scoring y detección de patrones latentes en el comportamiento del cliente.

Acción

Campañas personalizadas, ofertas diferenciadas, estrategias de retención proactiva y optimización de la cartera crediticia.

Evolución: del marketing masivo al marketing analítico

1960 – 1980

Marketing masivo

Comunicación unidireccional. Segmentación geográfica básica. Sin personalización.

1980 – 1995

Marketing directo

Primeras bases de datos de clientes. Correo directo segmentado. Listas de mailings.

1995 – 2010

CRM analítico

Sistemas CRM integrados. Modelos estadísticos de propensidad. Data warehousing.

2010 –hoy

Marketing analítico

Machine Learning, Big Data, personalización en tiempo real, CLV predictivo, omnicanalidad.

En el sector financiero argentino, la transición hacia el marketing analítico se aceleró con la expansión de las fintech y la digitalización bancaria post-2015.

El ciclo operativo del Database Marketing

1 Recolección

Captura de datos desde core bancario, CRM, canales digitales, bureau de crédito y fuentes externas.

2 Integración

Consolidación en una vista única del cliente (single customer view). Deduplicación, normalización, enriquecimiento.

3 Análisis

Segmentación, scoring de propensidad, modelos de churn, estimación de CLV. Aquí opera la minería de datos.

4 Acción

Campañas personalizadas, ofertas diferenciadas, acciones de retención, pricing dinámico, gestión de cobranza.

5 Medición

Evaluación de resultados, ROI de campaña, test A/B, retroalimentación al modelo. Ciclo iterativo.

El ciclo es iterativo: los resultados de la fase 5 retroalimentan las fases 1 a 3, generando aprendizaje continuo.

Customer Lifetime Value (CLV)

Valor total que un cliente aporta a la empresa a lo largo de toda su relación comercial. Métrica vertebral del Database Marketing que permite priorizar inversiones en adquisición vs. retención.

$$CLV = \Sigma\ (Margen \times Retención^t) / (1 + Tasa\ de\ descuento)^t$$

donde t = período, Retención = probabilidad de permanencia, Margen = ingreso neto por período

CLV Histórico

Suma de márgenes pasados reales del cliente. Simple de calcular pero retrospectivo. No anticipa comportamiento futuro. Útil como benchmark.

CLV Predictivo

Modelos probabilísticos (BG/NBD, Pareto/NBD). Incorpora probabilidad de churn futura. Permite acciones proactivas. Estándar en banca y fintech.

Segmentación de carteras: enfoques analíticos

Segmentación RFM

Recencia, Frecuencia, Monto. Clasifica clientes por comportamiento transaccional reciente. Ampliamente utilizada en banca retail y e-commerce.

Segmentación por valor

Agrupa clientes según su contribución económica (CLV). Permite identificar el 20% de clientes que genera el 80% del margen (principio de Pareto).

Clustering algorítmico

K-Means, DBSCAN, clustering jerárquico. Descubre segmentos latentes sin criterios predefinidos. Requiere feature engineering cuidadoso.

Segmentación por riesgo

Agrupa clientes por probabilidad de default, mora o abandono. Fundamental para la gestión del riesgo crediticio y la asignación de provisiones.

Análisis RFM: Recencia, Frecuencia, Monto

R

Recencia

Tiempo transcurrido desde la última transacción. Clientes recientes tienen mayor probabilidad de respuesta a campañas.

Días desde última compra/transacción

F

Frecuencia

Cantidad de transacciones en un período definido. Indicador de vinculación y lealtad del cliente con la entidad.

Nº transacciones en últimos 12 meses

M

Monto

Volumen monetario acumulado de las transacciones. Proxy del valor económico directo que el cliente representa.

Suma total en $ del período

Implementación: cada dimensión se discretiza en quintiles (1–5), generando segmentos como «Champions» (5-5-5), «At Risk» (1-3-3) o «Hibernating» (1-1-1). Python: librería lifetimes; R: paquete rfm.

Modelos de propensidad en el sector financiero

Estiman la probabilidad de que un cliente ejecute una acción específica. Permiten priorizar recursos y personalizar estrategias comerciales.

Propensión al churn

Probabilidad de abandono del servicio. Habilita acciones de retención proactiva antes de que el cliente se vaya.

Propensión a la compra

Probabilidad de adquisición de un nuevo producto (cross-sell / up-sell). Optimiza campañas comerciales.

Propensión al pago

Probabilidad de regularización de deuda. Prioriza acciones de cobranza en deudores con mayor chance de pago.

Propensión al default

Probabilidad de incumplimiento crediticio. Base del scoring regulatorio que determina la admisión y pricing.

Algoritmos típicos: Regresión Logística (estándar regulatorio), Random Forest, Gradient Boosting, XGBoost.

Caso: Segmentación de cartera bancaria

Un banco comercial argentino con 500.000 clientes retail necesita diseñar estrategias diferenciadas para optimizar la rentabilidad de su cartera de préstamos personales y tarjetas de crédito.

Comprensión del negocio	Objetivo: reducir churn en 15% y aumentar cross-sell en 10%. KPIs: tasa de abandono, productos por cliente, margen neto.
Datos disponibles	Core bancario (saldos, movimientos), CRM (interacciones), bureau de crédito (score Veraz/Nosis), datos demográficos (SISCEN).
Segmentación propuesta	RFM para comportamiento transaccional + clustering k-means para perfiles de riesgo-rentabilidad. Resultado: 6 segmentos accionables.
Estrategia por segmento	Champions → programa de fidelización premium. At Risk → campaña de retención con oferta personalizada. Lost → análisis de win-back.

Este caso articula CRISP-DM (Clase 1) con Database Marketing (Clase 2) y anticipa técnicas de las Unidades 2–5.

Fuentes de datos económico-financieros: panorama general

Institucionales argentinas	Repositorios académicos	Organismos multilaterales	Fuentes privadas
BCRA (Central de Deudores)	Kaggle (competencias y datasets)	Banco Mundial (WDI, Findex)	Bureau de crédito (Veraz, Nosis)
INDEC (EPH, Censos económicos)	UCI ML Repository (benchmark)	BID (base de indicadores)	Core bancario / CRM
SISCEN (datos demográficos)	OpenML (datasets estandarizados)	CEPAL (CEPALSTAT)	Proveedores de datos alternativos
Ministerio de Economía	Google Dataset Search	FMI (datos macroeconómicos)	APIs financieras (Alpha Vantage)

Central de Deudores del BCRA

Registro integral de la situación crediticia de todas las personas físicas y jurídicas con deudas en el sistema financiero formal argentino. Fuente primaria para la evaluación de riesgo crediticio.

Situación del deudor

Categorías 1 a 6: Normal, Con seguimiento especial, Con problemas, Alto riesgo de insolvencia, Irrecuperable, Irrecuperable por disposición técnica.

Variables disponibles

CUIT/CUIL, entidad, tipo de financiación, monto de deuda, días de atraso, garantías, situación crediticia histórica (últimos 24 meses).

Acceso y formato

Consulta individual gratuita en bcra.gob.ar. Descarga masiva para entidades reguladas. Formato: CSV/XLS. Actualización mensual.

Uso en minería de datos

Variable objetivo para scoring crediticio. Feature de riesgo histórico. Validación de modelos internos. Base para CLV ajustado por riesgo.

INDEC, SISCEN y datos gubernamentales

Encuesta Permanente de Hogares (EPH)

Datos trimestrales sobre ingresos, empleo, educación, vivienda. Microdatos descargables. Permite construir perfiles socioeconómicos territoriales. Fundamental para contextualizar modelos financieros.

Censos económicos y poblacionales

Datos a nivel de radio censal. Variables demográficas exhaustivas. Permiten enriquecer bases de clientes con indicadores de zona (NBI, nivel educativo promedio, densidad poblacional).

Sistema SISCEN

Datos demográficos detallados. Registro de personas. Complemento para verificación de identidad y enriquecimiento de bases de datos de clientes.

Datos abiertos (datos.gob.ar)

Portal nacional de datos abiertos. Datasets sobre empleo, comercio exterior, industria, precios. Formato CSV/JSON descargable. API de acceso programático.

Relevancia: estas fuentes permiten enriquecer los modelos de minería de datos con variables macroeconómicas y sociodemográficas de contexto.

Kaggle y UCI ML Repository

Kaggle

Plataforma de competencias de datos y repositorio de datasets abiertos con +300.000 datasets disponibles.

Datasets que utilizaremos:

- Telco Customer Churn (proyecto integrador)
- Credit Card Fraud Detection
- Home Credit Default Risk
- Lending Club Loan Data

Ventaja: notebooks compartidos, discusiones de la comunidad, rankings de soluciones.

UCI ML Repository

Repositorio académico de referencia con datasets curados para investigación en machine learning desde 1987.

Datasets relevantes:

- German Credit (Statlog) — ya lo exploramos
- Australian Credit Approval
- Default of Credit Card Clients
- Bank Marketing (Portuguese bank)

Ventaja: datasets canónicos con papers de referencia, reproducibilidad, benchmarks establecidos.

Organismos multilaterales: datos abiertos

Banco Mundial

`data.worldbank.org`

World Development Indicators (WDI): +1.400 indicadores para 217 economías. Global Findex: inclusión financiera. Datos de pobreza, desigualdad, comercio.

BID

`data.iadb.org`

Indicadores de desarrollo de América Latina y el Caribe. Datos sobre empleo, productividad, infraestructura, inclusión financiera regional.

CEPAL

`statistics.cepal.org`

CEPALSTAT: base integral de estadísticas de la región. Series de PIB, comercio exterior, empleo, pobreza, distribución del ingreso.

FMI

`data.imf.org`

International Financial Statistics (IFS): tipos de cambio, tasas de interés, balanza de pagos. World Economic Outlook (WEO): proyecciones macroeconómicas.

Estos datos macroeconómicos contextualizan los modelos micro: un modelo de scoring mejora al incorporar variables como inflación, desempleo o tipo de cambio.

Tipología de variables en bases financieras

Categoría	Variables típicas	Fuente habitual	Ejemplo
Demográficas	Edad, género, estado civil, nivel educativo, localización	Core bancario, SISCEN, INDEC	Edad: 35; Provincia: Misiones
Transaccionales	Saldos, movimientos, consumos, transferencias, pagos	Core bancario, procesadora de tarjetas	Promedio mensual de consumo: $85.000
Comportamiento digital	Frecuencia de login, uso de app, canal preferido	Banca digital, CRM, analítica web	Accesos app/mes: 42; Canal: mobile
Crediticias	Score Veraz/Nosis, situación BCRA, días de atraso	Bureau de crédito, Central de Deudores	Score: 750; Situación: 1 (Normal)
Macroeconómicas	Inflación, tipo de cambio, tasa BADLAR, desempleo	BCRA, INDEC, FMI	Inflación mensual: 4.2%; USD/ARS: 1.350

La riqueza de un modelo de minería de datos en finanzas depende directamente de la diversidad y calidad de las variables incorporadas al análisis.

Calidad de datos: problemas típicos en bases financieras

Valores faltantes

Variables incompletas por fallas en captura, migraciones de sistemas o clientes que no declaran información. Mecanismos: MCAR, MAR, MNAR (Rubin, 1976).

Registros duplicados

Un mismo cliente con múltiples registros por variantes en nombre, DNI o datos de contacto. Requiere deduplicación con lógica difusa (fuzzy matching).

Inconsistencias

Ingresos negativos, edades imposibles, fechas futuras, montos en distintas monedas sin conversión. Validación de reglas de negocio.

Sesgo temporal

Distribuciones que cambian en el tiempo (concept drift). Un modelo entrenado con datos pre-pandemia puede ser inútil post-pandemia.

Desbalanceo de clases

Proporción asimétrica entre clases (ej.: 3% de defaults vs. 97% de no-defaults). Tema central de la Unidad 4 del curso.

Data leakage

Información del futuro que se filtra al entrenamiento. Ej.: usar el resultado del crédito como variable predictora del otorgamiento.

La Unidad 2 (clases 3 y 4) abordará en profundidad el tratamiento de cada uno de estos problemas con técnicas específicas.

PRÁCTICA GUIADA · GOOGLE COLAB

Carga y exploración de un dataset financiero real

Primera inmersión en código: exploración del German Credit Dataset y un dataset de cartera bancaria

Python

```python
import pandas as pd
from sklearn.datasets import fetch_openml
import seaborn as sns
import matplotlib.pyplot as plt

# Carga del dataset
credit = fetch_openml(
    'credit-g', version=1, as_frame=True
)
df = credit.frame

# Exploración inicial
df.info()
df.describe()
df['class'].value_counts()
```

R (tidyverse)

```r
library(tidyverse)
library(readr)
library(skimr)

# Carga del dataset
df <- read_csv("german_credit.csv")

# Exploración inicial
glimpse(df)
skim(df)
df %>%
  count(class) %>%
  mutate(prop = n / sum(n))
```

Objetivos: verificar dimensiones, tipos de datos, distribución de la variable objetivo, primeras visualizaciones descriptivas.

Glosario de términos clave — Clase 2

Database Marketing

Disciplina que articula gestión de BD y marketing analítico para maximizar el CLV.

CLV

Customer Lifetime Value. Valor total que un cliente aporta a lo largo de la relación comercial.

RFM

Recencia, Frecuencia, Monto. Modelo de segmentación basado en comportamiento transaccional.

Propensidad

Probabilidad estimada de que un cliente ejecute una acción específica (churn, compra, pago).

Churn

Abandono del cliente. Métrica crítica en negocios de suscripción y banca retail.

Cross-sell / Up-sell

Venta cruzada de productos adicionales / venta de versiones superiores al mismo cliente.

Central de Deudores

Registro del BCRA con la situación crediticia de personas físicas y jurídicas.

Bureau de crédito

Empresa que recopila y vende información crediticia (Veraz, Nosis en Argentina).

Single customer view

Vista unificada del cliente integrando datos de múltiples sistemas fuente.

Concept drift

Cambio en las distribuciones de los datos a lo largo del tiempo. Degrada modelos.

Data leakage

Filtración de información futura o del test set al entrenamiento. Produce métricas infladas.

Fuzzy matching

Técnicas de coincidencia aproximada para deduplicar registros con variantes textuales.

CIERRE DE LA CLASE 2

Actividad práctica de cierre

EJERCICIO GRUPAL

Caso: Diseño de estrategia de Database Marketing

Una fintech argentina de préstamos personales online con 200.000 usuarios activos necesita reducir su tasa de churn del 18% mensual y aumentar el cross-sell de seguros.

Diseñar una estrategia de Database Marketing que incluya: fuentes de datos a utilizar, variables clave, tipo de segmentación propuesta y modelos de propensidad recomendados.

PRÓXIMA CLASE — JUE 23/04

Unidad 2: Preparación y Exploración de Datos

- EDA en datasets financieros.
- Tratamiento de valores faltantes: MCAR, MAR, MNAR (Rubin, 1976).
- Detección y tratamiento de outliers.
- Notebook guiado completo con matplotlib, seaborn y ggplot2.

LECTURA SUGERIDA PARA LA CLASE 3

Capítulo 2 de los Apuntes de Cátedra: «Preparación y Exploración de Datos». Familiarizarse con el dataset Telco Customer Churn en Kaggle: descargar, abrir en Colab y ejecutar df.info() y df.describe().

M M D

MAESTRÍA EN MINERÍA DE DATOS · UTN FACULTAD REGIONAL ROSARIO

Aplicaciones de Minería de Datos a Economía y Finanzas

Clase 2 — Database Marketing y Fuentes de Datos

Dr. Darío Ezequiel Díaz

drdarioezequieldiaz@gmail.com

¡Gracias por participar!