M M D

MAESTRÍA EN MINERÍA DE DATOS · UTN FACULTAD REGIONAL ROSARIO

Aplicaciones de Minería de Datos a Economía y Finanzas

Clase 3 — EDA, Valores Faltantes y Outliers

Dr. Darío Ezequiel Díaz

drdarioezequieldiaz@gmail.com

Jueves 23 de abril de 2026 · 18:00–22:00 hs

Hoja de ruta de la clase

01 **Recapitulación de la Clase 2**
Database Marketing, fuentes de datos, calidad del dato

02 **Análisis Exploratorio de Datos (EDA)**
Concepto, herramientas, estadísticos descriptivos, visualizaciones

03 **Valores faltantes: taxonomía de Rubin**
MCAR, MAR, MNAR — diagnóstico, imputación y comparación de estrategias

04 **Detección y tratamiento de outliers**
IQR, z-score modificado (MAD), Mahalanobis, winsorización

05 **Pipeline integrado de calidad de datos**
Flujo completo: desde el dato crudo hasta el dataset listo para modelar

06 **Práctica guiada en Google Colab**
Notebooks de valores faltantes y outliers — Python y R

RECAPITULACIÓN · CLASE 2

¿Qué construimos la semana pasada?

Database Marketing

Concepto, ciclo operativo, CLV, pilares Datos-Analítica-Acción.

Segmentación y RFM

Recencia, Frecuencia, Monto. Segmentos Champions → Hibernating.

Fuentes de datos

BCRA, INDEC, Kaggle, UCI, Banco Mundial, BID, CEPAL, FMI.

Calidad del dato

Faltantes, duplicados, inconsistencias, sesgo temporal, desbalanceo, leakage.

Hoy profundizamos en la preparación de datos: EDA + tratamiento de faltantes y outliers con código en Python y R.

Análisis Exploratorio de Datos (EDA)

«Exploratory data analysis can never be the whole story, but nothing else can serve as the foundation stone.»
— John W. Tukey, Exploratory Data Analysis, 1977

Comprender

Dimensiones, tipos de datos, estructuras, relaciones entre variables. ¿Qué tengo?

Diagnosticar

Faltantes, outliers, inconsistencias, desbalanceo. ¿Qué problemas hay?

Hipotétizar

Relaciones candidatas para el modelado. ¿Qué patrones sugieren los datos?

Caja de herramientas del EDA

Categoría	Herramientas	Python	R
Tendencia central	Media, mediana, moda	`df.mean(), df.median()`	`mean(), median()`
Dispersión	Desvío, IQR, CV, rango	`df.std(), df.describe()`	`sd(), IQR(), summary()`
Forma	Asimetría, curtosis	`df.skew(), df.kurtosis()`	`skewness(), kurtosis()`
Frecuencias	Tablas, proporciones	`df.value_counts()`	`table(), count()`
Correlación	Pearson, Spearman, Cramér	`df.corr(), sns.heatmap()`	`cor(), corrplot()`
Visualización	Histograma, boxplot, scatter	`sns.histplot(), sns.boxplot()`	`ggplot() + geom_*()`

El EDA no es un paso mecánico: exige mirada crítica, contextualización financiera e iteración con el negocio.

Mecanismos de Rubin (1976): MCAR, MAR, MNAR

MCAR *Missing Completely At Random*

P(R | Y) = P(R | φ). La ausencia no depende de ninguna variable. Puramente aleatoria.

Error del servidor que omite registros al azar.

Listwise ✅ · Media ✅ · KNN ✅ · MICE ✅

MAR *Missing At Random*

P(R | Y_obs, Y_mis) = P(R | Y_obs, φ). La ausencia depende de variables observadas, no del valor faltante.

Jóvenes no reportan ingreso; condicionado a edad, la ausencia no depende del ingreso.

Listwise ❌ · Media ❌ · KNN ✅ · MICE ✅

MNAR *Missing Not At Random*

P(R | Y_obs, Y_mis) ≠ P(R | Y_obs, φ). La ausencia depende del valor faltante mismo.

Deudores con ingresos bajos no los declaran precisamente por ser bajos.

Listwise ❌ · Media ❌ · KNN ❌ · MICE ❌

Protocolo diagnóstico: ¿qué mecanismo opera?

1

Cuantificar

% faltantes por variable y registro. missingno.matrix() en Python; naniar::vis_miss() en R.

2

Test de Little

H_0: MCAR. Si $p < 0.05$, se rechaza MCAR → MAR o MNAR. naniar::mcar_test() en R.

3

Regresión logística

Modelar P(R=0 | X). Si AUC > 0.55, las observadas predicen la ausencia → MAR.

4

Correlación point-biserial

cor.test(R, X) por variable. Correlaciones significativas confirman MAR.

5

Juicio de dominio

¿Existe razón sustantiva para que el valor extremo no se reporte? → MNAR.

Regla práctica: asumir MAR por defecto. Reservar MNAR para variables con mecanismo de ocultamiento activo (ingreso, patrimonio, deuda informal).

Estrategias de imputación: comparación

Método	Complejidad	Cuándo usarlo	Limitación principal	Python / R
Eliminación (listwise)	Simple	Solo bajo MCAR. Datos abundantes.	Pierde datos. Sesgo si no MCAR.	`df.dropna() / na.omit()`
Media / Mediana	Simple	Exploración rápida. Variables numéricas.	Subestima varianza. Sin relaciones.	`SimpleImputer / median()`
KNN Imputation	Media	MAR. Estructura local en los datos.	Costoso en datasets grandes.	`KNNImputer / VIM::kNN()`
MICE (PMM/CART)	Alta	MAR. Múltiples variables con relaciones.	Asume MAR. Requiere convergencia.	`IterativeImputer / mice()`
MissForest	Alta	Datos mixtos. Alta dimensionalidad.	Lento. Hiperparámetros.	`— / missForest::missForest()`

⚠️ **NUNCA imputar sobre todo el dataset antes del train_test_split. Fit en train, transform en test. Pipeline encapsulado obligatorio.**

Outliers en datos financieros: el desafío

En finanzas, la frontera entre un outlier genuino y un dato erróneo resulta difusa. Un crédito por $50.000.000 puede ser un error de captura o un cliente high net worth. Un ingreso de $0 puede ser un faltante disfrazado o un desempleado real. La decisión de tratamiento requiere criterio contextualizado, no reglas mecánicas.

Error de captura

Dato imposible: ingreso negativo, edad = 250, fecha futura. Acción: corregir o eliminar.

Outlier genuino

Valor extremo pero legítimo: cliente de alto patrimonio, transacción corporativa. Acción: winsorizar o conservar.

Outlier informativo

El caso de interés: fraude, lavado de activos, comportamiento anómalo. Acción: NO eliminar — es el target.

Método IQR (Tukey fences)

$$\text{Outlier si: } x < Q_1 - k \cdot IQR \quad \text{o} \quad x > Q_3 + k \cdot IQR$$

$$\text{donde } IQR = Q_3 - Q_1, \quad k = 1.5 \text{ (estándar) o } k = 3 \text{ (estricto)}$$

Ventajas

Simple, intuitivo, no paramétrico. No requiere supuesto de normalidad. Implementación inmediata.

Limitaciones

No considera relaciones multivariadas. Sensible a la distribución: en variables lognormales (montos financieros), detecta demasiados outliers legítimos.

Mejora: IQR contextualizado

Aplicar IQR dentro de segmentos (edad, provincia, tipo de empleo). Un ingreso de $2M es outlier para un empleado público pero no para un ejecutivo financiero.

Z-score modificado (MAD)

El z-score clásico $z = (x - \bar{x}) / s$ es sensible a los propios outliers (que inflan $\bar{x}$ y s). El z-score modificado reemplaza media y desvío por mediana y MAD:

$$M_i = 0.6745 \cdot (x_i - \tilde{x}) / MAD \quad \text{donde} \quad MAD = \text{mediana}(|x_i - \tilde{x}|)$$

Sospechoso si $|M_i| > 3.5$ (Iglewicz & Hoaglin, 1993)

Breakdown point: 50%

Hasta un 50% de valores extremos no afectan la detección. El z-score clásico tiene breakdown point = 0% (un solo outlier extremo lo distorsiona). Propiedad esencial en bases financieras donde clientes high-value representan proporciones significativas.

Implementación

```
Python:
from scipy.stats import median_abs_deviation
MAD = median_abs_deviation(x)
M = 0.6745 * (x - np.median(x)) / MAD

R:
MAD <- mad(x, constant=1)
M <- 0.6745 * (x - median(x)) / MAD
```

Estrategias de tratamiento de outliers

Winsorización	Recortar al percentil elegido (ej.: P1/P99). Conserva el registro, acota el valor extremo. Implementación: scipy.stats.mstats.winsorize() / DescTools::Winsorize().
Transformación log	log(x) o log(1+x). Reduce asimetría y comprime valores extremos. Ideal para variables monetarias (credit_amount, ingreso). Reversible para interpretación.
Variable indicadora	Crear flag binario is_outlier = 1. El modelo decide si el outlier aporta información predictiva. No se pierde dato ni se modifica.
Eliminación	Última opción. Solo para errores confirmados (ingreso < 0, edad > 120). NUNCA eliminar outliers en detección de fraude: son el target.
Capping / Flooring	Fijar límites hard: mín = P5, máx = P95. Similar a winsorización pero con umbrales fijos de negocio. Usado en scoring regulatorio.

Pipeline integrado: del dato crudo al dataset modelable

1	**EDA inicial**	Dimensiones, tipos, distribuciones, correlaciones. Hipótesis de negocio.
2	**Diagnóstico de faltantes**	Cuantificar → Little → regresión logística → identificar mecanismo.
3	**Imputación**	MICE/KNN bajo MAR. Media/mediana solo como exploración rápida.
4	**Detección de outliers**	IQR contextualizado + z-score MAD. Clasificar: error vs. genuino vs. informativo.
5	**Tratamiento de outliers**	Winsorizar/log-transform genuinos. Corregir/eliminar errores. Conservar informativos.
6	**Validación**	Comparar distribuciones pre/post. Verificar que no se introdujo sesgo ni leakage.

Este pipeline se ejecuta ANTES del train_test_split. El split debe ser la primera operación; luego cada paso se aplica fit en train, transform en test.

Glosario de términos clave — Clase 3

EDA

Exploratory Data Analysis. Análisis previo al modelado (Tukey, 1977).

MCAR

Missing Completely At Random. Ausencia independiente de todo.

MAR

Missing At Random. Ausencia depende de variables observadas.

MNAR

Missing Not At Random. Ausencia depende del valor faltante.

Test de Little

Test formal de H_0: MCAR. Estadístico χ^2 (Little, 1988).

MICE

Multiple Imputation by Chained Equations. Imputación iterativa.

IQR

Interquartile Range. $Q_3 - Q_1$. Base del método de Tukey.

MAD

Median Absolute Deviation. Medida robusta de dispersión.

Z-score modificado

Detección de outliers robusta con MAD. Breakdown = 50%.

Winsorización

Recorte de valores extremos al percentil elegido.

Ignorabilidad

Propiedad que permite inferencia sin modelar el mecanismo (Rubin).

Pipeline

Secuencia encapsulada: fit en train, transform en test.

CIERRE DE LA CLASE 3

Actividad práctica y anticipación

ENTREGA PARCIAL: INFORME EDA

Sobre el German Credit Dataset o el Telco Customer Churn, elaborar un informe EDA que incluya:

· Estadísticos descriptivos y visualizaciones
· Diagnóstico de valores faltantes (mecanismo)
· Detección de outliers con IQR y z-score MAD
· Conclusiones y recomendaciones para el modelado

Formato: Notebook en Colab (Python o R). Entrega: Clase 4.

PRÓXIMA CLASE — JUE 30/04

Unidad 2: Feature Engineering y Selección de Variables

- Feature engineering con sentido económico.
- Transformación: normalización, estandarización, Box-Cox.
- Codificación: one-hot, label, target encoding.
- Selección: filter, wrapper, embedded (Lasso, RF).
- Multicolinealidad: diagnóstico con VIF.

LECTURA SUGERIDA PARA LA CLASE 4

Capítulo 2 de los Apuntes de Cátedra: secciones de Feature Engineering y Selección de Variables. Explorar el dataset Telco Customer Churn en Kaggle: identificar variables candidatas a transformación y features derivadas que tengan sentido para el problema de churn.

M M D

MAESTRÍA EN MINERÍA DE DATOS · UTN FACULTAD REGIONAL ROSARIO

Aplicaciones de Minería de Datos a Economía y Finanzas

Clase 3 — EDA, Valores Faltantes y Outliers

Dr. Darío Ezequiel Díaz

drdarioezequieldiaz@gmail.com

¡Gracias por participar!