MAESTRÍA EN MINERÍA DE DATOS · UTN FACULTAD REGIONAL ROSARIO

CLASE 5 · UNIDAD 3

Regresión logística *y scoring crediticio*

Fundamentos matemáticos, odds ratio, construcción de scorecards y estándar regulatorio de Basilea

Dr. Darío Ezequiel Díaz

Jueves 7 de mayo de 2026 · 18:00 – 22:00 hs · Modalidad virtual

Plan de la sesión

Cuatro bloques articulados que recorren los fundamentos teóricos, la interpretación económica, la construcción de la scorecard y la implementación práctica en Python y R.

01

Fundamentos matemáticos

Función sigmoide, modelo logístico, transformación logit y estimación por máxima verosimilitud.

02

Interpretación económica

Odds ratio, lectura de coeficientes en lenguaje financiero, ejemplo numérico aplicado.

03

Scorecard y regulación

De la PD al puntaje (Siddiqi). Factor, offset, PDO. Basilea II/III y BCRA.

04

Implementación práctica

sklearn, statsmodels, glm() y scorecard package. Métricas: AUC, KS y Gini.

Bienvenidos a la Unidad 3

Modelos de clasificación aplicados a finanzas

Durante las próximas tres clases (5, 6 y 7) desplegaremos el arsenal completo de algoritmos de clasificación supervisada. Avanzaremos desde el modelo lineal interpretable hasta los ensambles modernos y las redes neuronales, manteniendo siempre el anclaje en el negocio financiero.

CLASE 5 · HOY

Regresión logística

Scoring crediticio y scorecards

CLASE 6 · 14/05

CART · Random Forest

Árboles y ensambles bagging

CLASE 7 · 21/05

Gradient Boosting · SVM · NN

Boosting, kernels y redes

Hoy: el modelo lineal interpretable que sigue siendo el estándar regulatorio de la banca mundial.

¿Por qué empezar por regresión logística?

Pese al protagonismo mediático del deep learning y los métodos de ensamble, la regresión logística conserva una posición de privilegio en el modelado financiero. Cuatro razones explican su vigencia:

1 Estándar regulatorio

Aceptada por BCRA, Fed, BCE y EBA como modelo benchmark bajo Basilea II/III. Cada coeficiente es auditable.

2 Interpretabilidad total

El exponencial de cada coeficiente entrega un odds ratio con lectura económica directa, sin recurrir a SHAP.

3 Base de la scorecard

La aditividad logit habilita la construcción de tarjetas de puntaje aplicables en sucursal de manera estandarizada.

4 Benchmark de comparación

Todo modelo avanzado (RF, XGBoost, NN) debe superar significativamente a la logística para justificar su complejidad.

Clasificación binaria en finanzas

La regresión logística aborda problemas donde la variable objetivo Y toma dos valores: el evento de interés (Y = 1) ocurre o no ocurre (Y = 0). El espacio aplicativo en el ámbito financiero resulta vastísimo:

Default crediticio

¿Incumplirá el solicitante el pago de su préstamo? Y=1 default; Y=0 paga.

Detección de fraude

¿Esta transacción es fraudulenta? Y=1 fraude; Y=0 legítima.

Churn / abandono

¿El cliente cancelará el servicio? Y=1 baja; Y=0 retención.

Propensión a la compra

¿Aceptará el cliente una oferta de cross-sell? Y=1 acepta; Y=0 rechaza.

¿Por qué no usar regresión lineal?

Si la respuesta fuera binaria, ¿bastaría con ajustar $Y = \beta_0 + \beta_1 X + \varepsilon$ y aplicar mínimos cuadrados? La intuición es tentadora, pero conduce a tres problemas insalvables:

Probabilidades fuera de [0,1]

La recta puede arrojar predicciones negativas o superiores a 1, sin interpretación válida como probabilidad.

Heterocedasticidad estructural

La varianza de un error binario depende de X: $\mathrm{Var}(\varepsilon|X) = p(X)\cdot(1-p(X))$. El supuesto OLS se rompe.

No linealidad real

La relación entre P(Y=1) y X suele ser sigmoide: tramos planos en ambos extremos y pendiente máxima en el centro.

Solución: transformar la combinación lineal mediante una función que mapee $\mathbb{R} \to (0,1)$ y respete la forma sigmoide observada en los datos reales. Esta función es la logística.

La función logística (sigmoide)

Propuesta por Verhulst en 1838 para modelar el crecimiento poblacional, la función logística transforma cualquier valor real en una probabilidad. Constituye el corazón del clasificador:

$$\sigma(z) = 1 / (1 + e^{-z})$$

Mapea cualquier valor real $z \in \mathbb{R}$ al intervalo abierto (0, 1)

Acotada

$0 < \sigma(z) < 1$ para todo z. Apta para interpretarse como probabilidad.

Monótona

Estrictamente creciente: a mayor z, mayor probabilidad estimada.

Simétrica

$\sigma(0) = 0.5$; $\sigma(-z) = 1 - \sigma(z)$. Punto de máxima pendiente en el origen.

El modelo de regresión logística

Componiendo la sigmoide con una combinación lineal de predictores $X = (X_1, X_2, \ldots, X_p)$, obtenemos un modelo de probabilidad condicional plenamente especificado:

$$P(Y = 1 \mid X) = 1 / (1 + \exp(-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_p X_p)))$$

Probabilidad de pertenecer a la clase positiva dado el vector de covariables

Predictor lineal

$$\eta = \beta_0 + \beta_1 X_1 + \ldots + \beta_p X_p$$

Combinación lineal usual de las variables, en escala $\mathbb{R}$.

Función de enlace

$$g(p) = \log(p / (1-p))$$

El logit conecta probabilidad con predictor lineal.

Respuesta probabilística

$$p = \sigma(\eta) \in (0, 1)$$

La predicción es una probabilidad, no una clase.

De odds a log-odds: el logit

Si despejamos la combinación lineal del modelo, descubrimos una identidad fundamental que conecta tres lenguajes equivalentes: probabilidad, odds y log-odds.

$$\text{logit}(p) = \log(p / (1 - p)) = \beta_0 + \beta_1 X_1 + \ldots + \beta_p X_p$$

Los log-odds son una función lineal de las covariables — y aquí radica la magia del modelo

Probabilidad	Odds	Log-odds (logit)
p = 0.10	0.11	−2.20
p = 0.50	1.00	0.00
p = 0.90	9.00	+2.20

Estimación por máxima verosimilitud

A diferencia de la regresión lineal, no disponemos de una solución cerrada por mínimos cuadrados. Los coeficientes β se estiman maximizando la log-verosimilitud bajo el supuesto de independencia condicional de las observaciones.

$$\ell(\beta) = \Sigma_i \; [\; y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i) \;]$$

donde $p_i = \sigma(x_i^T\beta)$. Se busca $\hat{\beta}$ que maximice $\ell(\beta)$

Método numérico

Newton-Raphson o IRLS (Iteratively Reweighted Least Squares). En la práctica, sklearn ofrece varios solvers: 'liblinear', 'lbfgs', 'saga' o 'newton-cg' según el tamaño del problema y la regularización.

Inferencia estadística

Los errores estándar de $\hat{\beta}$ se derivan de la matriz de información de Fisher. Habilitan tests de Wald, intervalos de confianza y la prueba de razón de verosimilitud para comparar modelos anidados.

El odds ratio: la lectura económica

El verdadero poder del modelo logístico radica aquí: cada coeficiente, transformado exponencialmente, expresa cuánto multiplica las chances de la clase positiva un incremento unitario de la variable.

$$OR_i = \exp(\beta_i)$$

Cambio multiplicativo en los odds por cada unidad adicional de X_i, manteniendo el resto fijo

$\beta > 0 \rightarrow OR > 1$

Incrementa el riesgo

Aumenta la probabilidad de la clase positiva. Variable de signo adverso para el bien (p. ej., default).

$\beta = 0 \rightarrow OR = 1$

Sin efecto

La variable no aporta información: la probabilidad estimada no cambia con su valor (no significativa).

$\beta < 0 \rightarrow OR < 1$

Reduce el riesgo

Disminuye la probabilidad de la clase positiva. Variable protectora del fenómeno modelado.

Ejemplo: coeficientes interpretados

Modelo de default sobre German Credit Dataset (variable Y = bad/good). Ilustramos la lectura conjunta del coeficiente, su odds ratio y su significado económico.

Variable	β̂	exp(β̂)	Lectura económica
Duración (meses)	+0.030	1.030	*Cada mes adicional eleva los odds de default en 3.0%*
Monto del crédito (×1000)	+0.008	1.008	*Cada $1.000 adicional eleva los odds de default en 0.8%*
Edad (años)	−0.018	0.982	*Cada año adicional reduce los odds de default en 1.8%*
Historial crediticio: bueno	−0.825	0.438	*Buen historial reduce los odds en un 56.2% frente al rating crítico*
Propósito: vehículo nuevo	+0.652	1.919	*Crédito para auto nuevo casi duplica los odds vs. educación*

Nota: *para variables categóricas, el OR se interpreta contra la categoría de referencia. Para continuas, contra el incremento de una unidad.*

De la probabilidad al puntaje

Una probabilidad de default de 0.1834 no resulta operativa para un oficial de cuenta en sucursal. La industria bancaria traduce la PD a una escala de puntaje (score) intuitiva y estandarizada: la scorecard.

PASO 1

Modelo logístico

Se ajusta una regresión logística sobre las variables del solicitante. Se obtienen los $\hat{\beta}$.

PASO 2

Cálculo de PD

Para cada solicitante se calcula $\hat{p} = \sigma(x\,\hat{\beta})$, su probabilidad estimada de default.

PASO 3

Transformación lineal

Mediante factor y offset, los log-odds se convierten en una escala monótona de puntos.

PASO 4

Scorecard final

Cada atributo aporta un sub-score parcial. La suma total es el puntaje del solicitante.

La aditividad del logit es lo que hace técnicamente viable la scorecard: los aportes se suman.

Construcción técnica de la scorecard

Siguiendo a Siddiqi (2017), el puntaje se define por una transformación lineal de los log-odds. Tres parámetros gobiernan la escala:

$$\text{Score} = \text{Offset} + \text{Factor} \cdot \ln(\text{Odds})$$

donde Factor = PDO / ln(2) y Offset = Score_target − Factor · ln(Odds_target)

PDO

Points to Double the Odds

Cantidad de puntos que duplica los odds. Configuración usual: 20 puntos (FICO) o 40 puntos.

PDO = 20

Score_target

Puntaje de anclaje

Puntaje asignado a un nivel de referencia. Suele fijarse en 600 puntos para odds 50:1 (1 default cada 50 buenos).

600 puntos

Odds_target

Odds de anclaje

Razón de odds asociada al Score_target. Configuración estándar de la industria: 50 a 1.

Odds = 50:1

Basilea II/III y el rol regulatorio

Los acuerdos de Basilea exigen a las entidades financieras estimar la PD (probability of default) bajo enfoques IRB (Internal Ratings-Based) con modelos auditables y explicables. La regresión logística satisface estos criterios sin sacrificios.

Interpretabilidad

Cada coeficiente debe poder justificarse en lenguaje económico ante el supervisor.

Estabilidad temporal

Monitoreo continuo del PSI y de la performance. Recalibración periódica obligatoria.

Validación independiente

Áreas de validación interna y auditoría externa revisan periódicamente el modelo.

Documentación exhaustiva

Cada decisión metodológica debe documentarse: variables, transformaciones, pruebas.

BCRA — Comunicación «A» 5398 y normativas posteriores: *los modelos internos deben ser auditables, explicables y aprobados por la SEFyC.*

Implementación en Python

Dos librerías centrales: scikit-learn para predicción y pipelines productivos; statsmodels para inferencia estadística rigurosa (errores estándar, p-valores, intervalos de confianza).

Python · scikit-learn

```python
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score

modelo = LogisticRegression(
    penalty='l2', C=1.0,
    solver='lbfgs', max_iter=1000,
    random_state=2026)

modelo.fit(X_train, y_train)
p_hat = modelo.predict_proba(X_test)[:,1]
auc = roc_auc_score(y_test, p_hat)
```

Python · statsmodels

```python
import statsmodels.api as sm
import numpy as np

X_const = sm.add_constant(X_train)
logit = sm.Logit(y_train, X_const).fit()

print(logit.summary())

# Odds ratios e IC al 95%
OR  = np.exp(logit.params)
IC  = np.exp(logit.conf_int())
```

Implementación en R

R ofrece glm() como motor estadístico clásico y el paquete scorecard como solución integral de la industria: binning supervisado, WOE, IV y construcción automatizada de la tarjeta de puntaje.

R · stats::glm()

```r
modelo <- glm(
  class ~ duration + amount + age,
  data   = train_set,
  family = binomial(link='logit'))

summary(modelo)

# Odds ratios
exp(coef(modelo))
exp(confint(modelo))
```

R · scorecard package

```r
library(scorecard)

# 1. Binning supervisado y WOE
bins <- woebin(german, y='class')
dt_woe <- woebin_ply(german, bins)

# 2. Modelo + scorecard final
m  <- glm(class~., dt_woe, family=binomial)
card <- scorecard(bins, m,
        points0=600, odds0=1/19, pdo=20)
```

Métricas iniciales y supuestos del modelo

Profundizaremos la evaluación en la Unidad 5. Aquí presentamos las tres métricas mínimas que la industria reporta junto a cualquier scorecard, y los supuestos cuya verificación condiciona la validez del modelo.

MÉTRICAS DE PERFORMANCE

AUC-ROC

Área bajo la curva ROC. Mide la capacidad discriminante. Industria: AUC ≥ 0.70 aceptable; ≥ 0.75 bueno.

KS (Kolmogorov-Smirnov)

Máxima separación entre las distribuciones acumuladas de buenos y malos. KS ≥ 0.30 es el umbral mínimo.

Gini = 2·AUC − 1

Equivalente lineal al AUC en escala [0,1]. Lectura directa y comparable. Gini ≥ 0.40 aceptable.

SUPUESTOS Y LIMITACIONES

Linealidad en los logits

La relación entre cada X_i y $\log(p/(1-p))$ debe ser lineal. Test: Box-Tidwell o splines.

Independencia de observaciones

Inválida en series temporales o datos panel sin tratamiento adecuado (GEE, efectos aleatorios).

Ausencia de multicolinealidad severa

VIF > 5-10 distorsiona los β. Diagnosticar en la fase de feature engineering (Clase 4).

Tamaño de muestra suficiente

Regla práctica: ≥ 10 eventos por variable predictora (regla EPV de Peduzzi).

CIERRE DE LA CLASE 5

Actividad práctica y anticipación

ENTREGA PARCIAL · CLASE 6

Caso: scorecard sobre German Credit

- Ajustar un modelo logístico con ≥ 5 variables
- Reportar $\hat{\beta}$, $\exp(\hat{\beta})$ e IC al 95%
- Construir scorecard con PDO=20, anchor 600/50:1
- Calcular AUC, KS y Gini sobre el set de testeo
- Interpretar económicamente 3 coeficientes clave

Formato: Notebook en Colab (Python o R). Entrega: Clase 6.

PRÓXIMA CLASE — JUE 14/05

Clase 6: Árboles y Random Forest

- CART: criterios de partición (Gini, entropía)
- Poda: pre-poda y post-poda (cost-complexity)
- Random Forest: bagging y doble aleatorización
- Importancia de variables: MDI y permutation
- Comparativa con logística sobre el mismo set

De modelos lineales a modelos basados en particiones.

LECTURA SUGERIDA: Apunte de Cátedra · Unidad 3 · sección 3.1. Siddiqi, N. (2017) *Intelligent Credit Scoring*, capítulos 8–9.